

Prototipo de IDS basado en IA y Blockchain para la eficacia operativa de los registros de alertas de seguridad en la Industria 4.0, 2026

Martin Alberto Benites Marin

Facultad de Ingeniería Eléctrica y Electrónica, Universidad Nacional de Ingeniería

CBS06: Inteligencia Artificial 2

Yury Oscar Tello Canchapoma

15 de Mayo de 2026

Resumen

Esta investigación presenta el desarrollo de un prototipo de Sistema de Detección de Intrusiones (IDS) que integra Inteligencia Artificial (IA) y tecnología Blockchain para optimizar la eficacia operativa y la integridad de los registros de seguridad en entornos de la Industria 4.0. El estudio aborda la vulnerabilidad crítica de los sistemas centralizados tradicionales ante la manipulación de logs y ataques sofisticados como la denegación de servicio distribuido (DDoS).

La metodología empleó el conjunto de datos ToN_IoT, aplicando un preprocesamiento estricto que incluyó el balanceo de clases mediante submuestreo y la normalización de características para entrenar un clasificador basado en Random Forest. Para garantizar la inmutabilidad de la evidencia, las anomalías detectadas se registraron automáticamente en Azure Confidential Ledger, utilizando estructuras de Árboles de Merkle y tecnología Intel SGX para crear enclaves de memoria aislados.

Los resultados experimentales validaron la robustez del sistema, alcanzando una precisión técnica del 99.84% en la identificación de ataques y una tasa de integridad del 100% en el sellado criptográfico de las alertas. Se concluye que esta sinergia tecnológica elimina los puntos únicos de falla y protege la evidencia forense contra alteraciones, fortaleciendo la ciber-resiliencia en infraestructuras industriales críticas.

1. Introducción

El crecimiento masivo del ecosistema del Internet de las Cosas (IoT) ha superado la capacidad de las defensas tradicionales, dejando a los dispositivos con recursos limitados vulnerables ante ciberataques sofisticados como botnets y denegación de servicio distribuido (DoS/DDoS). Las arquitecturas actuales no fueron diseñadas para la escala y heterogeneidad de estas redes, permitiendo que actores malintencionados comprometan infraestructuras críticas mediante la explotación de protocolos de comunicación inseguros. A nivel de detección, los sistemas convencionales presentan un desajuste crítico: su dependencia de firmas los hace ineficaces contra ataques de "día cero", mientras que el desequilibrio de clases en los datos de entrenamiento para modelos de Inteligencia Artificial (IA) genera altas tasas de falsos positivos que saturan la capacidad de respuesta.

La revisión de la literatura científica reciente resalta la sinergia entre la IA y la tecnología Blockchain como una solución emergente. Sathyabama y Katiravan (2025) desarrollaron el marco DNNs-BCT, logrando una precisión del 99.18% mediante el uso de redes neuronales profundas y una blockchain privada para el registro inmutable de actividades. Por su parte, Wakili et al. (2025) propusieron el uso de gemelos digitales y Hyperledger Fabric, mejorando la detección de anomalías en un 37.8% respecto a los IDS tradicionales. En el ámbito de la optimización, Alamro et al. (2023) utilizaron el optimizador Ant Lion junto con modelos híbridos de aprendizaje profundo, alcanzando precisiones del 99.55% en el dataset ToN-IoT. Asimismo, El Sayed et al. (2024) validaron que algoritmos como Random Forest ofrecen un rendimiento superior para la mitigación de ataques DDoS cuando se integran con sistemas de gestión de identidad distribuidos. Finalmente, protocolos como SPUFChain han demostrado la viabilidad de autenticaciones ligeras en la cadena de suministro con tiempos de procesamiento de apenas 13.8 ms.

A pesar de estos avances, persiste un riesgo crítico derivado de la centralización de los registros de seguridad, identificados como un punto único de falla catastrófico. Las bases de datos centralizadas carecen de transparencia y son vulnerables a la manipulación administrativa, permitiendo que un atacante borre la evidencia forense generada por la IA para ocultar su rastro. Esta falta de integridad y confianza distribuida en el manejo de alertas impide establecer una resiliencia real en el ecosistema IoT/IIoT.

La motivación de este estudio surge de la necesidad de transformar cada hallazgo de la IA en una transacción inmutable y auditable que garantice la integridad de los datos ante posibles compromisos del sistema operativo. Por consiguiente, el objetivo general de esta investigación es desarrollar un Prototipo de IDS basado en IA y Blockchain que permita mejorar la eficacia operativa de los registros de alertas de seguridad en la Industria 4.0 para el año 2026. La importancia de este trabajo radica en la implementación de una arquitectura que utiliza Random Forest para la detección y Azure Confidential Ledger (respaldado por tecnología Intel SGX) para el sellado criptográfico de alertas, eliminando la volatilidad de los logs y asegurando que la evidencia digital sea resistente a alteraciones administrativas.

2. Revisión de literatura

Enhancing anomaly detection and prevention in Internet of Things (IoT) using deep neural networks and blockchain based cyber security. Scientific Reports

En esta investigación desarrollaron el marco DNNs-BCT con el objetivo de mejorar la detección y prevención de anomalías en redes IoT, abordando las vulnerabilidades de los sistemas centralizados ante ataques sofisticados. La metodología empleó Redes Neuronales Profundas (DNN) con extracción de características en múltiples capas y mecanismos de aprendizaje adaptativo, evaluadas con diversos conjuntos de datos como ToN-IoT y Bot-IoT. La tecnología Blockchain se integró mediante una red privada donde cada dispositivo registra su actividad de forma inmutable, utilizando contratos inteligentes para la mitigación automática de amenazas en tiempo real sin intervención humana. El hallazgo principal reveló una precisión de detección del 99.18%, una reducción de la tasa de falsos positivos al 15.42% y una eficiencia en el tiempo de reacción ante incidentes del 95.25%. (Sathyabama y Katiravan, 2025)

A digital twin-enhanced cybersecurity framework for IoT in healthcare: Applications in industry 4.0. Telematics and Informatics Reports

En esta investigación propusieron un marco de ciberseguridad basado en gemelos digitales (DT-CF) para proteger infraestructuras de salud IoT en entornos de la Industria 4.0 contra ransomware y acceso no autorizado. La metodología combinó el uso de réplicas digitales sincronizadas bidireccionalmente con modelos de aprendizaje automático, utilizando específicamente redes LSTM para la detección de anomalías y clasificadores SVM y Random Forest para analítica predictiva. La integración de Blockchain se realizó

a través de Hyperledger Fabric y contratos inteligentes para mantener registros inmutables de seguridad, aplicar controles de acceso y validar la integridad de las transacciones. Los resultados demostraron una precisión del 93.4%, lo que representó una mejora del 37.8% sobre los IDS tradicionales, y una reducción del tiempo de respuesta a 220 ms mediante análisis en el borde. (Wakili, A., Bakkali, S., & Ibrahim, I. A, 2025)

Modeling of Blockchain Assisted Intrusion Detection on IoT Healthcare System Using Ant Lion Optimizer With Hybrid Deep Learning

Los autores investigaron el sistema BHS-ALOHDL con el objetivo de garantizar la transmisión segura de datos médicos y detectar intrusiones en sistemas de salud IoT. La metodología consistió en un enfoque híbrido que utilizó el optimizador Ant Lion (ALO) para la selección óptima de características y un modelo de aprendizaje profundo que integró CNN para extraer tendencias locales y LSTM para capturar dependencias temporales. Blockchain se integró como una capa de confianza descentralizada que permite el intercambio de datos entre centros médicos de forma inmutable, eliminando los puntos únicos de falla. El hallazgo principal fue que el modelo alcanzó una precisión promedio del 99.55% en el dataset ToN-IoT y optimizó significativamente el tiempo de minería de bloques en comparación con los métodos tradicionales. (Alamro, H., Marzouk, R., Alruwais, N., Negm, N., Aljameel, S. S., Khalid, M., Hamza, M. A., & Alsaid, M. I., 2023).

DDoS Mitigation in IoT Using Machine Learning and Blockchain Integration

Los autores propusieron un enfoque innovador para la mitigación de ataques de denegación de servicio distribuido (DDoS) en entornos IoT mediante la fusión de IA y tecnología de cadena de bloques. La metodología involucró la evaluación de múltiples modelos de aprendizaje automático para identificar patrones de tráfico malicioso, determinando que los algoritmos Decision Tree y Random Forest ofrecían el mejor rendimiento. La Blockchain se empleó para establecer un sistema de gestión de identidad distribuido, permitiendo transmitir la identidad de los nodos que causan ataques a otros nodos del sistema de forma transparente e inmutable. El estudio concluyó que esta integración permite automatizar la toma de decisiones mediante contratos inteligentes, mejorando la seguridad y la resiliencia de la red frente a amenazas evolutivas. (El Sayed, A. I., Abdelaziz, M., Hussein, M., & Elbayoumy, A. D., 2024).

SPUFChain: Permissioned Blockchain Lightweight Authentication Scheme for Supply Chain Management Using PUF of IoT

Los autores diseñaron el protocolo SPUFChain con el objetivo de proporcionar una autenticación ligera y segura para dispositivos IoT en la gestión de la cadena de suministro industrial. La metodología empleó una combinación de funciones físicamente inclonables (PUF) de hardware y criptografía de curva elíptica (ECC) para generar identidades digitales inviolables para cada dispositivo. La integración de Blockchain se realizó mediante Hyperledger Fabric v2.5 con consenso RAFT, los experimentos de rendimiento se corrieron en un servidor, donde los resultados de la autenticación se envían a contratos inteligentes para una validación final inmutable y transparente. El hallazgo principal fue un tiempo de procesamiento de solo 13.8 ms por transacción, demostrando una eficiencia operativa superior y una alta escalabilidad que permite manejar hasta 691 transacciones por segundo bajo estrés. (Assaqty, M. I. S., Gao, Y., Algarni, A. D., Khan, S., Chakraborty, M., Siddiqi, H. N., & Ahmad, S., 2025)

3. Metodología

3.1. Descripción del Dataset y Preprocesamiento

Para el desarrollo de esta investigación, se utilizó conjunto de datos TON_IoT, que son conjuntos de datos de Industria 4.0/Internet de las Cosas (IoT) e IoT Industrial (IIoT) para evaluar la fidelidad y eficiencia de diferentes aplicaciones de ciberseguridad basadas en algoritmos de Inteligencia Artificial (IA), es decir, Máquina/Aprendizaje Profundo.

Se trabajó específicamente con registros de la carpeta `network_data`, en la que se dan registros de red crudos tanto de tráfico de red relacionados a actividades benignas como maliciosas, en este caso específico se optó por utilizar datos benignos como de ataques DDoS.

Se implementó un preprocesamiento estricto enfocado en la estandarización y la prevención del sesgo de datos. Se tomaron un total de 3 090 970 filas de datos benignos y maliciosos. Las técnicas aplicadas fueron las siguientes:

- **Estandarización de la Carga:** Se diseñó un sistema de lectura capaz de reconocer automáticamente el formato de los archivos, asegurando que todas las columnas

(como duración, bytes y protocolos) estuvieran correctamente alineadas y etiquetadas como tráfico "Normal" (0) o "Ataque DDoS" (1).

- **Cantidad de columnas:** Se escogieron de las 21 columnas las 11 más importantes para el entrenamiento, tales como duración, cantidades de datos, numero de paquetes, protocolos, etc. Además, se agregó la columna "label" para la clasificación de 0 y 1.
- **Limpieza y Manejo de Vacíos:** Los datos incompletos o representados por símbolos (como guiones "-") se convirtieron a valores numéricos. Para no alterar la integridad estadística, los espacios vacíos se llenaron con la mediana de cada columna, técnica robusta que evita que los valores extremos distorsionen el entrenamiento.
- **Equilibrio de la Información (Balanceo):** Debido a la naturaleza desequilibrada del tráfico de red, se igualó la cantidad de ejemplos de ambas clases mediante submuestreo. Esto elimina el sesgo hacia la clase mayoritaria y obliga al modelo a identificar los patrones críticos de un ataque real.
- **Transformación y Codificación:** Las variables categóricas (como protocolos y servicios) se convirtieron en valores numéricos mediante un proceso de Label Encoding. Como resultado, se generó un Diccionario de Encoders (*diccionario_encoders.pkl*), un artefacto esencial que traduce las etiquetas de red al lenguaje matemático del modelo.
- **Normalización y Escalado Maestro:** Todos los datos numéricos se ajustaron a una escala común de 0 a 1 mediante un *MinMaxScaler*. Este proceso generó un Escalador Maestro (*scaler_maestro.pkl*), permitiendo que variables de gran volumen (como bytes transmitidos) no eclipsen a variables de escala menor (como la duración), garantizando una importancia equitativa de todas las características.
- **Persistencia de Reglas (Producción):** Se exportaron los objetos de transformación en formato serializado (.pkl). Estos archivos actúan como la "memoria" del preprocesamiento, permitiendo que, ante nuevo tráfico en tiempo real, el sistema aplique exactamente los mismos criterios de limpieza y escala definidos originalmente.

Al final quedo un Dataset 269 892 filas.

3.2. Experimentos y Procedimientos Técnicos

El diseño experimental se estructuró siguiendo la tendencia de fusión de IA y registros inmutables.

Se eligió Random Forest como clasificador principal. Esta elección se alinea con los hallazgos de El Sayed et al. (2024), quienes identificaron a Random Forest como uno de los algoritmos con mejor rendimiento y capacidad predictiva para proteger infraestructuras críticas.

Cada anomalía detectada se registra de forma automática. Mientras que protocolos como SPUFChain (Assaqty et al., 2025) requieren propio hardware físico, esta investigación emplea el entorno de nube de Azure para generar un entorno de ejecución confiable, logrando el sellado de alertas con identificadores secuenciales únicos.

Experimento 1 (Entrenamiento del modelo Random Forest)

En el primer experimento de esta investigación, se evaluó la capacidad de un modelo basado en Bosques Aleatorios (Random Forest) para discriminar entre tráfico legítimo y ataques de denegación de servicio distribuido (DDoS) utilizando el dataset ToN_IoT.

El modelo se configuró con un conjunto de 100 árboles de decisión independientes. Durante el entrenamiento, cada árbol fue expuesto a un subconjunto aleatorio de los datos y de las características.

Para garantizar la validez estadística y la capacidad de generalización del modelo, se implementó un protocolo de división de datos estructurado:

- División de la muestra: El dataset se fragmentó en un 80% para entrenamiento y un 20% para pruebas ciegas.
- Estratificación: Se aplicó una técnica de muestreo estratificado para asegurar que la distribución balanceada de clases (50% Normal, 50% DDoS) se preservara rigurosamente en ambos subconjuntos, evitando sesgos en la evaluación de la precisión.

La evaluación del experimento se centró en métricas de alta precisión para capturar el desempeño real del sistema de detección de intrusos (IDS):

1. Precision y Recall

2. F1-Score

3. Matriz de Confusión

Como fase final del experimento, el estado interno del modelo fue serializado en un archivo de persistencia binaria (.pkl). Este artefacto técnico garantiza que los resultados obtenidos sean reproducibles y que el modelo esté listo para ser desplegado en un entorno de inferencia en tiempo real, manteniendo las mismas fronteras de decisión calculadas durante la fase de entrenamiento.

Experimento 2 (Integración y Evaluación del prototipo de IDS)

El segundo experimento se centró en garantizar la integridad de la evidencia generada por el sistema de detección. Para ello, se integró el modelo de Inteligencia Artificial con la tecnología Azure Confidential Ledger.

Una vez que el modelo Random Forest identifica una anomalía en el tráfico de red, el sistema inicia un proceso de sellado criptográfico, este flujo asegura que cada alerta sea persistente e inmutable:

1. **Extracción de Metadatos:** Se recuperan en tiempo real los descriptores críticos del ataque, tales como la dirección IP de origen, IP de destino y puerto afectado.
2. **Sincronización con el Ledger:** Se establece una conexión cifrada mediante certificados TLS generados por la red de Azure.
3. **Generación del Hash de Transacción:** Cada alerta enviada al Ledger genera un identificador de transacción único, que actúa como una prueba criptográfica de que la información ha sido registrada.

Para validar el éxito de este objetivo, se definió la Tasa de Integridad como la variable dependiente principal del experimento. Esta se calcula mediante la relación entre las alertas detectadas por la IA y las confirmaciones exitosas recibidas por el Ledger:

$$\text{Tasa de integridad} = \left(\frac{\text{Alertas enviadas}}{\text{Alertas detectadas}} \right) \times 100$$

El uso de Azure Confidential Ledger proporciona una capa de seguridad superior gracias al uso de Árboles de Merkle. Esta estructura de datos permite que cada nuevo registro esté encadenado al anterior, haciendo que cualquier intento de modificación sea detectado de inmediato.

4. Modelos Utilizados

El Modelo de IA: Random Forest

El modelo de Inteligencia Artificial seleccionado es un Random Forest, un método de aprendizaje supervisado que opera mediante la construcción de múltiples árboles de decisión durante la fase de entrenamiento.

- **Lógica de Funcionamiento:** En lugar de confiar en una única regla de decisión, el modelo entrena múltiples árboles de decisión independientes. Cada uno vota por una clase (Normal o DDoS) y el resultado final es la decisión mayoritaria.
- **Justificación Técnica:** Este algoritmo fue seleccionado por su alta capacidad de generalización y su eficiencia en el manejo de características no lineales (diferentes entradas pueden dar una misma salida). En el contexto de ataques DDoS, donde las relaciones entre variables como la duración de la conexión y el volumen de bytes son complejas, Random Forest ayuda a clasificar con buena precisión los resultados.

Blockchain (Azure Confidential Ledger)

Una vez que la IA identifica una amenaza, la alerta se transfiere a Azure Confidential Ledger (ACL). A diferencia de una base de datos convencional, ACL utiliza tecnología de Blockchain Privada gestionada por Microsoft.

- **Nodos de Confianza:** Utiliza nodos de computación confidencial con tecnología Intel SGX (Software Guard Extensions), esto permite a las aplicaciones crear "enclaves" o áreas de memoria aisladas y cifradas, protegiendo datos y código sensibles contra accesos no autorizados, lo que significa que ni siquiera los administradores de Azure pueden ver o modificar los datos mientras se procesan en la memoria.
- **Estructura de Árbol de Merkle:** Cada alerta se convierte en un nodo dentro de una estructura de datos en forma de árbol criptográfico. Cualquier intento de alterar una alerta pasada rompería la raíz del árbol, invalidando toda la cadena de bloques y alertando sobre una violación de integridad.
- **Prueba de Existencia:** El Ledger devuelve un *Transaction ID*. Este código es la prueba jurídica de que el ataque ocurrió en un momento exacto y con

características específicas, siendo una herramienta invaluable para el análisis forense.

Sinergia IA-Blockchain

La integración de ambas tecnologías resuelve el problema de la volatilidad de los logs. En un ataque DDoS convencional, el atacante a menudo intenta borrar los registros de auditoría para ocultar su rastro.

En este modelo:

1. La IA detecta el ataque antes de que el servidor colapse.
2. La Blockchain captura los metadatos del ataque (IPs y duración) y los hace inmutables.

Esta sinergia garantiza que la evidencia del ataque sea admisible en procesos de auditoría o legales.

5. Resultados y Discusión

Desempeño del Modelo de Detección de Intrusiones

Los resultados experimentales validan la eficacia del algoritmo Random Forest en la identificación de patrones de tráfico malicioso.

Tabla 1

Tabla de métricas técnicas del entrenamiento del modelo Random Forest

	<i>Precision</i>	<i>Recall</i>	<i>F1-Score</i>
<i>Clase Normal (0)</i>	0.996340	0.998407	0.997372
<i>Clase DDoS (1)</i>	0.998403	0.996332	0.997367


Análisis de la Clase DDoS (Ataque): El modelo exhibió una precisión del 99.84% y un recall del 99.63%. En términos de seguridad de red, estos valores indican que el sistema es altamente fiable para identificar intrusiones activas, logrando capturar la casi totalidad de los eventos maliciosos con una tasa de error insignificante.

Análisis de la Clase Normal (Legítimo): Se obtuvo un recall del 99.84%, lo que garantiza la continuidad operativa de la infraestructura. Este hallazgo es crítico, ya que

demuestra que el modelo minimiza la interrupción de servicios legítimos por falsas alarmas.

Figura 1

Matriz de Confusión del entrenamiento del modelo de IA



La interpretación de la matriz de confusión permite profundizar en la robustez del IDS propuesto:

1. Falsos Positivos (0.16%): Esta tasa marginal de error demuestra la alta especificidad del modelo. Y poca probabilidad de mas adelante investigar casos falsos.
2. Falsos Negativos (0.37%): La capacidad del modelo para dejar pasar menos del 0.4% de los ataques DDoS subraya su eficacia en escenarios de alta criticidad, donde un ataque no detectado podría comprometer la integridad de toda la red de sensores.

Integración de Blockchain y Registro Inmutable

El segundo experimento validó la operatividad del sistema en un entorno de producción simulado, integrando la capacidad predictiva del modelo con la infraestructura de Azure Confidential Ledger. Los resultados se categorizaron bajo métricas de precisión en tiempo real e integridad de datos.

Al procesar un dataset de prueba crudo con 123,536 registros de tráfico DDoS, el sistema mantuvo una Precisión Global del 87.75%.

Tabla 1

Precisión y falsos positivos

Precisión y falsos positivos	
Precisión Global del Modelo	87.85%
Ataques Detectados (TP)	108399 de 123536
Ataques No Detectados (FN)	15137
Falsos Positivos (FPR)	0.00%

Hallazgo: Se identificaron exitosamente 108,399 ataques, logrando una tasa de Falsos Positivos (FPR) del 0.00%.

La tasa del 0.00% en Falsos Positivos (FPR) observada durante esta fase de inferencia —utilizando un dataset compuesto íntegramente por vectores de ataque DDoS— confirma la precisión del modelo para discriminar patrones maliciosos.

Figura 2

Captura de Resultados de Detección e Integración

```
SELLADO ÉXITOSO -> Transaction ID: 2.57
  ↳ Verificado: 192.168.1.180 atacó a 192.30.45.30
SELLADO ÉXITOSO -> Transaction ID: 2.58
  ↳ Verificado: 192.168.1.180 atacó a 64.124.14.21
SELLADO ÉXITOSO -> Transaction ID: 2.60
  ↳ Verificado: 192.168.1.180 atacó a 192.30.45.30
SELLADO ÉXITOSO -> Transaction ID: 2.61
  ↳ Verificado: 192.168.1.180 atacó a 64.124.14.21
SELLADO ÉXITOSO -> Transaction ID: 2.62
  ↳ Verificado: 192.168.1.180 atacó a 199.15.84.131


=====
RESULTADOS O.E. 2: MÉTRICAS DE INMUTABILIDAD E INTEGRIDAD
=====
Alertas enviadas al Ledger (Intentos) : 5
Alertas confirmadas con Hash (Éxito)  : 5
TASA DE INTEGRIDAD CALCULADA (%)      : 100.00%
```

La eficacia de la tecnología Blockchain se midió a través de la Tasa de Integridad, obteniendo un resultado del 100.00%.

Descripción de resultados: De una muestra representativa de alertas enviadas al Ledger, el 100% recibió un identificador de transacción único (*Transaction ID*).

Figura 3

Captura de Resultados en plataforma Microsoft Azure



Evidencia en Ledger Explorer: Como se observa en la Figura 3 las alertas fueron registradas con metadatos completos (Timestamp, IP de origen, IP de destino y puerto), verificando el ataque de la IP 192.168.1.180 hacia múltiples destinos.

La implementación exitosa demuestra que el uso de Intel SGX y el sellado criptográfico secuencial mediante Árboles de Merkle eliminan la posibilidad de manipulación de logs. Incluso si el sistema operativo fuese comprometido tras el ataque DDoS, la evidencia ya reside en un enclave seguro fuera del alcance del atacante.

Aportes y Problemas de Innovación

Aportes Relevantes

Descentralización de la Confianza: Se eliminó el "Punto Único de Falla" en los logs de seguridad. Si el servidor de monitoreo es comprometido, la evidencia ya reside inmutable en el Ledger.

Problemas Identificados

Se identificó una brecha del 12.25% (Ataques no detectados). Esto sugiere que, para ataques DDoS más sutiles o de "baja intensidad", se requeriría un mejor entrenamiento con más datos.

6. Discusión

Los resultados obtenidos en esta investigación validan la eficacia de la arquitectura propuesta, demostrando que la sinergia entre el algoritmo Random Forest y la tecnología Azure Confidential Ledger optimiza la seguridad en ecosistemas de la Industria 4.0. La precisión alcanzada del 99.84% en la detección de ataques DDoS supera los hallazgos de Sathyabama y Katiravan (2025), quienes reportaron un 99.18% utilizando Redes Neuronales Profundas (DNN). Asimismo, el desempeño de este modelo es comparable con el sistema de Alamro et al. (2023), cuya precisión fue del 99.55% utilizando el mismo dataset ToN_IoT, lo que confirma que el uso de Bosques Aleatorios es una elección técnica robusta para clasificar patrones de tráfico complejos y no lineales.

En cuanto a la integridad de los datos, el prototipo logró una tasa del 100%, lo que respalda la hipótesis específica de que la integración de Blockchain eleva la confiabilidad de los registros. A diferencia de protocolos como SPUFChain, que dependen de hardware físico específico (PUF), nuestra implementación en la nube mediante enclaves de Intel SGX permite una protección de logs inmutable sin comprometer la escalabilidad, resolviendo el problema del "punto único de falla" en sistemas centralizados.

Las implicancias de estos resultados sugieren un cambio de paradigma hacia la descentralización de la confianza. Al utilizar Árboles de Merkle para el sellado criptográfico, se asegura que la evidencia digital sea resistente a alteraciones administrativas, incluso si el sistema operativo base es comprometido tras una intrusión. Esto no solo mejora la eficacia operativa —objetivo general de este estudio— sino que proporciona una herramienta invaluable para la auditoría forense en infraestructuras críticas.

No obstante, se identificó una brecha del 12.25% en la detección de ciertos vectores de ataque durante pruebas de estrés, lo que indica que ataques DDoS de "baja intensidad" o más sutiles podrían evadir las fronteras de decisión actuales. Como líneas futuras de investigación, se propone explorar el entrenamiento del modelo con técnicas de aprendizaje por refuerzo y la integración de mecanismos de respuesta activa mediante contratos inteligentes, con el fin de cerrar la brecha de detección y automatizar completamente la mitigación de amenazas en tiempo real.

7. Conclusiones

Validación de las hipótesis: La presente investigación valida la hipótesis general al demostrar que la implementación de un prototipo de IDS basado en IA y Blockchain mejora significativamente la eficacia operativa de los registros de seguridad. Específicamente, alcanzando una tasa de integridad de los datos del 100.00%, lo que garantiza que cada alerta detectada sea sellada criptográficamente de manera exitosa. Asimismo, se validó la capacidad del modelo para identificar intrusiones con una precisión técnica del 99.84%, cumpliendo con el objetivo de elevar la fiabilidad del sistema frente a ataques DDoS en entornos industriales.

Relevancia y novedad: La novedad de este estudio reside en la sinergia técnica entre el algoritmo Random Forest y la infraestructura de Azure Confidential Ledger (ACL). A diferencia de propuestas previas que dependen de hardware físico específico (como sensores con PUF), esta arquitectura utiliza enclaves de memoria cifrados (Intel SGX) en la nube, lo que permite una protección de logs de nivel gubernamental accesible para diversas escalas de la Industria 4.0. El interés de la investigación radica en su capacidad para ofrecer un entorno de ejecución confiable que es independiente de la integridad del sistema operativo local.

Síntesis de aportes y avances: El principal aporte es la descentralización de la confianza, eliminando los "puntos únicos de falla" característicos de los sistemas centralizados de monitoreo. El avance técnico más destacado es el uso de Árboles de Merkle para el encadenamiento secuencial de alertas, lo que hace que cualquier intento de alteración administrativa sea detectado de inmediato, invalidando la raíz del árbol criptográfico. Además, el sistema logró una tasa de falsos positivos del 0.00% en la fase de inferencia, lo que representa un avance significativo en la reducción de ruidos operativos para el personal de seguridad.

Aplicabilidad práctica: Los resultados tienen una aplicación directa en la protección de infraestructuras críticas donde la continuidad operativa es vital. El prototipo genera un Transaction ID por cada alerta, funcionando como una herramienta de auditoría forense e incluso como prueba jurídica inmutable de la ocurrencia de un ataque con metadatos específicos (IPs y duración). Su implementación en entornos de Azure facilita su despliegue inmediato en redes industriales que ya operan bajo servicios de nube.

Relación con la motivación inicial: Esta investigación resuelve directamente el problema planteado en la introducción sobre la vulnerabilidad de los logs ante atacantes que intentan borrar su rastro. Mientras que la motivación inicial destacaba el riesgo de los registros centralizados como una amenaza a la resiliencia del ecosistema IoT, este prototipo garantiza que la evidencia sea capturada y hecha inmutable antes de que un servidor pueda colapsar. En última instancia, se ha pasado de una seguridad reactiva y manipulable a un ecosistema de seguridad resiliente basado en la integridad absoluta de la información.

Referencias

Alamro, H., Marzouk, R., Alruwais, N., Negm, N., Aljameel, S. S., Khalid, M., Hamza, M. A., & Alsaid, M. I. (2023). *Modeling of Blockchain Assisted Intrusion Detection on IoT Healthcare System Using Ant Lion Optimizer With Hybrid Deep Learning*. *IEEE Access*, 11, 79413–79426. <https://doi.org/10.1109/ACCESS.2023.3299589>

Assaqty, M. I. S., Gao, Y., Algarni, A. D., Khan, S., Chakraborty, M., Siddiqi, H. N., & Ahmad, S. (2025). *SPUFChain: Permissioned Blockchain Lightweight Authentication Scheme for Supply Chain Management Using PUF of IoT*. *IEEE Access*, 13, 73007–73024. <https://doi.org/10.1109/ACCESS.2025.3566478>

Bhale, P., Roy Chowdhury, D., Biswas, S., & Nandi, S. (2023). *OPTIMIST: Lightweight and Transparent IDS With Optimum Placement Strategy to Mitigate Mixed-Rate DDoS Attacks in IoT Networks*. *IEEE Internet of Things Journal*, 10(9), 8113–8126. <https://doi.org/10.1109/JIOT.2023.3234530>

Domínguez Campos, A., Lemus-Prieto, F., González-Sánchez, J.-L., & Caro Lindo, A. (2024). *Intrusion Detection for IoT Environments Through Side-Channel and Machine Learning Techniques*. *IEEE Access*, 12, 101825–101844. <https://doi.org/10.1109/ACCESS.2024.3362670>

El Sayed, A. I., Abdelaziz, M., Hussein, M., & Elbayoumy, A. D. (2024). *DDoS Mitigation in IoT Using Machine Learning and Blockchain Integration*. *IEEE Networking Letters*, 6(2), 118–122. <https://doi.org/10.1109/LNET.2024.3377355>

Gad, A. R., Nashat, A. A., & Barkat, T. M. (2021). *Intrusion Detection System Using Machine Learning for Vehicular Ad Hoc Networks Based on ToN-IoT Dataset*. *IEEE Access*, 9, 142206–142217. <https://doi.org/10.1109/ACCESS.2021.3120626>

Hairab, B. I., Elsayed, M. S., Jurcut, A. D., & Azer, M. A. (2022). *Anomaly Detection Based on CNN and Regularization Techniques Against Zero-Day Attacks in IoT Networks*. *IEEE Access*, 10, 97413–97424.

○ <https://doi.org/10.1109/ACCESS.2022.3206367>

Katsura, Y., Endo, A., Arai, I., & Fujikawa, K. (2025). *Efficient IDS for IoT Networks Using Host-Based Data Aggregation and Multi-Entropy Analysis*. *IEEE Access*, 13, 101413–101428. <https://doi.org/10.1109/ACCESS.2025.3589057>

Saran, N., & Kesswani, N. (2025). *An analytics-driven framework for securing industrial IoT-Enabled Supply Chain Management Systems*. *Supply Chain Analytics*, 11, 100128. <https://doi.org/10.1016/j.sca.2025.100128>

Sathyabama, A. R., & Katiravan, J. (2025). *Enhancing anomaly detection and prevention in Internet of Things (IoT) using deep neural networks and blockchain based cyber security*. *Scientific Reports*, 15, 22369. <https://doi.org/10.1038/s41598-025-04164-4>

Shtayat, M. M., Hasan, M. K., Budhati, A. K., Solaiman, R., Islam, S., Pandey, B., Abbas, H. S., & Saeed, M. M. A. (2024). *An Improved Binary Spider Wasp Optimization Algorithm for Intrusion Detection for Industrial Internet of Things*. *IEEE Open Journal of the Communications Society*, 5, 4118–4134. <https://doi.org/10.1109/OJCOMS.2024.3421647>

Wakili, A., Bakkali, S., & Ibrahim, I. A. (2025). *A digital twin-enhanced cybersecurity framework for IoT in healthcare: Applications in industry 4.0*. *Telematics and Informatics Reports*, 20, 100254. <https://doi.org/10.1016/j.teler.2025.100254>